Institut für Parallele und Verteilte Systeme

Universität Stuttgart Universitätsstraße 38 D–70569 Stuttgart

Masterarbeit

Lösungen für elastische Complex-Event-Processing Systeme

Benjamin Stutz

Studiengang: Softwaretechnik

Prüfer/in: Prof. Dr. Kurt Rothermel

Betreuer/in: Henriette Röger, M.Sc.

Beginn am: 16. April 2018

Beendet am: 16. Oktober 2018

Kurzfassung

 \ldots . Short summary of the thesis \ldots

Inhaltsverzeichnis

1	Einleitung	11					
2	Bestehende Arbeiten						
3	(15					
4	Parallelisieren von Operatoren	17					
5	Topologie-Modell	19					
6	Implementierug des Frameworks	21					
	 6.1 Graph-Modell 6.2 Modell-Steuerung 6.3 Steuerung der Skalierung 6.4 Hauptsteuerung 6.5 Kontroll-API 6.6 UML-Diagramm des Frameworks 	23 24 25 25 25 25					
7	Adapter für Heron	27					
	7.1 Implementierung	27 28 30 33					
8	Algorithmus mit Warteschlangen-Theorie	35					
	8.1 Implementation	36 40					
9	Algorithmus mit Regression	43					
	9.1 Implementation 9.2 Parameter	44 46					
10	Evaluation	49					
	10.1 Testdaten	49					
	10.2 Systemaufbau	50					
	10.3 Heron	50					
	10.4 Topologie	51					
	10.5 Ablauf	54					
	10.6 Parametrisierung der Algorithmen	54					
	10.7 Ergebnisse	56					

11 Zusammenfassung und Ausblick	57
Literaturverzeichnis	59

Abbildungsverzeichnis

6.1	Architektur des Systems	2
9.1	Graph der Zustandsübergänge [Zac+15]	4
	Anzahl Tupel pro Stunde	
10.2	Darstellung der logischen Topologie durch Heron UI	5

Tabellenverzeichnis

7.1	Operationen der REST-Schnittstelle		30
7.1	Operationen der REST-Schnittstelle		31
7.1	Operationen der REST-Schnittstelle		32
7.1	Operationen der REST-Schnittstelle		33
9.1	Hyperparamter		47
10.1	1 Parameter der Topologie		52
10.2	2 Parameter für den Warteschlangenalgorithmus		55
10.3	3 Parameter für den Algorithmus mit Regression		56

1 Einleitung

In diesem Kapitel steht die Einleitung zu dieser Arbeit. Sie soll nur als Beispiel dienen und hat nichts mit dem Buch [Wee+05] zu tun. Nun viel Erfolg bei der Arbeit!

Bei LETEX werden Absätze durch freie Zeilen angegeben. Da die Arbeit über ein Versionskontrollsystem versioniert wird, ist es sinnvoll, pro *Satz* eine neue Zeile im .tex-Dokument anzufangen. So kann einfacher ein Vergleich von Versionsständen vorgenommen werden.

Gliederung

Die Arbeit ist in folgender Weise gegliedert:

Kapitel ?? – ??: Hier werden werden die Grundlagen dieser Arbeit beschrieben.

Kapitel 11 – Zusammenfassung und Ausblick fasst die Ergebnisse der Arbeit zusammen und stellt Anknüpfungspunkte vor.

2 Bestehende Arbeiten

3 (

Hintergrund im CEP-Umfeld)

4 Parallelisieren von Operatoren

5 Topologie-Modell

6 Implementierug des Frameworks

Dieses Kapitel beschäftigt sich mit der Architektur und Impelentierung des Framworks. Das Framework schafft eine Abstraktionsebene für die Algorithmen, die die aktiven Topologien in den CEP-Systemem skalieren. Das Framework soll ermöglichen, die einzelnen Komponenten in der Topologie zu skalieren. Die logische Struktur der Topologie wird dabei nicht verändert. Das vorliegende Modell ermöglicht die Steuerung mehrerer CEP-Topologien, welche auch über diverse CEP-Systeme verteilt werden können.

6.0.1 Architektur

Die Architektur des Frameworks besteht aus mehreren logischen Komponenten und verfolgt zwei Ziele. Eines der beiden Hauptziele der Architektur ist, dass das System einfach um weitere Algorithmen erweitert werden kann. Um dieses Ziel zu erreichen, wurde eine Abstraktionsebene eingeführt, welche die Eigenschaften des realen CEP-Systems repräsentiert. Diese Abstraktion wird durch ein Graphen-Modell repräsentiert, welches einen gerichteten, azyklischen Graphen modelliert. Die implementierten Algorithmen arbeiten ausschließlich auf dem abstrahierten Modell. Für die Implementation eines neuen Algorithmus, müssen nur die Daten aus dem Modell ausgelesen und anschließend verarbeitet werden. Außerdem ist es möglich, mehrere Algorithmus für das gleiche Modell auszuführen um ihre Ergebnisse zu vergleichen. Um einen Algorithmus für das System zu implementieren ist ausschließlich Wissen über das Modell notwendig.

Ein weiteres Ziel ist, dass das System für weitere CEP-Systeme außer Heron verwendet werden kann. Dazu wurde eine API, die bereits in einer vorhergehenden Bachelorarbeit entwickelt wurde, erweitert. Alle Komponenten des Systems benutzen diese API für die Kommunikation mit dem CEP-System, sodass diese alle system-spezifischen Befehle abstrahieren kann. Die Seite der API, welche mit dem System direkt kommuniziert ist ein eigenständiger Adapter. Dieser Adapter wird auf dem Rechner installiert, von dem das zu steuernde CEP-System kontrolliert wird. Der Adapter ist über eine REST-API ansprechbar. Somit kann das Framework auf einem eigenständigen Rechner installiert werden und das Zielsystem über die REST-Schnittstelle des Adapters kontrollieren. Dies ermöglicht die Kontrolle von mehreren CEP-Systemen zur gleichen Zeit. Eine Erweiterung des Frameworks für weitere Systeme über die Implementierung eines entspreche4nden Adapters zu erreichen. Für die Erstellung eines neuen Adapters ist ausschließlich Wissen über die Spezifikation der REST-Schnittstelle notwendig. Das Framework kann so über die REST-API verschiedene CEP-Systeme über eine einheitlichen Schnittstelle ansprechen.

Die Architektur des Systems ist in der Abbildung 5.1 dargestellt. Im Folgenden werden die einzelnen Komponenten der Architektur genauer erläutert.

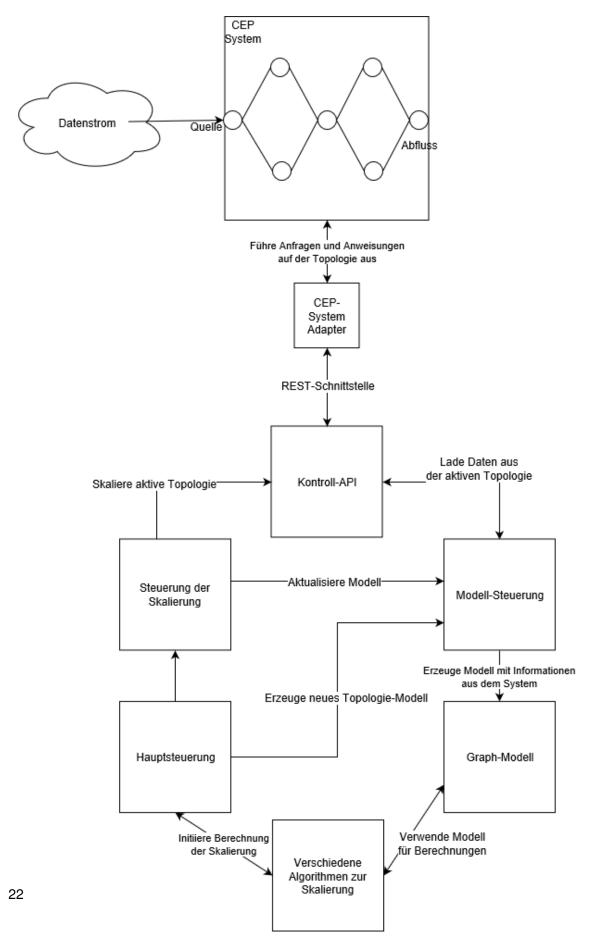


Abbildung 6.1: Architektur des Systems

6.1 Graph-Modell

Das Graph-Modell repräsentiert die Topologie im realen CEP-System. Alle Elemente der Topologie werden nach dem in Kapitel ********* vorgestellten Topologie-Modell abgebildet. Es dient als Cache für Messdaten aus dem realen System. Durch die Zwischenspeicherung wird ermöglicht, dass ein Modell eines bestimmten Zeitpunktes des realen Systems zur Verfügung gestellt werden kann. Würden die Algorithmen die Werte zur Laufzeit abfragen, also immer dann, wenn die Werte benötigt werden, kann dies zu einem inkonsistenten Modell führen. Die Algorithmen verwenden das Modell, um die Inkosistenz von Messungen zu verschiedenen Zeitpunkten zu verhindern.

Jedes Modell besteht aus Pfaden und Operatoren. Jeder Pfad stellt dabei eine geordnete Folge von Operatoren dar. Das Modell erlaubt kreuzende Pfade, sodass Operatoren in mehreren Pfaden verwendet werden können. Momentan kann im Modell keine selektive Weiterleitung der Tupel repräsentiert werden. Dies bedeutet, dass ein Operator alle Tupel, die er versendet, an immer an alle folgenden Operatoren weiterleitet. Operatoren sind über einen Namen identifizierbar und haben eine dem Parallelisierungsgrad entsprechende Anzahl an Tasks. Sobald der Operator einen neuen Parallelisierungsgrad erhält, wird die entsprechende Anzahl Tasks gelöscht oder erzeugt. Somit ist die Anzahl Tasks immer gleich dem Parallelisierungsgrad des Operators. Der maximale und minimale Parallelisierungsgrad aller Operatoren kann über zwei Konstanten angegeben werden. Diese gelten für alle Operatoren in allen Modellen. Ein logisch schlüssiger Minimalwert ist der Parallelisierungsgrad 1. Ein Parallelisierungsgrad kleiner als eins ist für einen aktiven Operator nicht gültig, da er keinen ausführenden Task besitzt. Das Maximum kann entsprechend der Ressourcen, die im CEP-System zur Verfügung stehen, angepasst werden. Pfade und Operatoren stellen die logische Struktur der Topologie dar.

Die ausführende Ebene, oder physische Struktur, wird durch Tasks und Kanäle repräsentiert. Tasks sind die Recheninstanzen welche die Operation eines Operators auf Tupel ausführen. In der vorliegenden Implementation des Graph-Modells ist die Zwischenspeicherung der Messwerte auf Task-Ebene vorgesehen. Somit wird ermöglicht, dass ein detailliertes Modell der Topologie im CEP-System erzeugt werden kann. Die ID der Tasks wird vom Operator automatisch erzeugt und wird aus dem Namen des Operators und einer fortlaufenden Nummer wie folgt gebildet: <*Name>_<Nummer>*. Die niedrigste Nummer ist immer die eins. Die höchste Nummer entspricht immer dem aktuellen Parallelisierungsgrad des Operators. Für Tasks sind folgende Messwerte in der aktuellen Version des Modells vorgesehen:

- Latenz des Tasks
- Anzahl Ausführungen des Tasks
- Anzahl eingehender Tupel
- · Anzahl ausgehender Tupel
- Auslastung
- Bearbeitungsdauer
- Tupel-Ankunftsintervall
- · Varianz der Bearbeitungsdauer
- Varianz des Tupel-Ankunftsintervalls

Für die Messwerte der Tasks wird die Annahme getroffen, dass sie unabhängig vom Pfad sind. Dies bedeutet zum Beispiel, dass alle eingehenden Tupel die selbe Bearbeitungsdauer benötigen. Unabhängig davon von welchem vorhergehenden Operator sie stammen. Alle für den Task erfassten Metriken differenzieren nicht die Herkunft der Tupel, sondern erfassen sie gesammelt.

Für viele Algorithmen wird nicht der Messwert eines einzelnen Tasks betrachtet, jedoch können die Werte gemittelt werden um einen aussagekräftigen Messwert für den gesamten Operator zu bekommen.

Die Kommunikation zwischen den Tasks wird durch die Kanäle repräsentiert. Diese speichern Metriken der Kommunikationskanäle zwischen Tasks. Für die Implementation des Modells wurde die Annahme getroffen, dass alle Tasks eines Operators mit allen Tasks der vorhergehenden und nachfolgenden Operatoren kommunizieren können. Die Anzahl an Kanälen zwischen zwei Operatoren ist also das Produkt aus deren Parallelisierungsgraden. Für Kanäle sind folgende Messwerte vorgesehen:

- Latenz des Kanals
- Latenz der Stapelverarbeitung

Details zu den Messwerten werden in Kapitel ******* erläutert.

6.2 Modell-Steuerung

Die Modell-Steuerung erzeugt die Modellstruktur der Topologien und füllt diese anschließend mit Messwerten. Alle Aktionen werden von der Hauptsteuerung initiiert. Im ersten Schritt wird die Topologie vom CEP-System über die Kontroll-API ausgelesen. Welche Topologie ausgelesen wird entscheidet die angegebene Adapteradresse. Ein Adapter ist jeweils für eine Topologie zuständig. Zuerst werden die Pfade der Topologie ausgelesen und im Graph-Modell die entsprechenden Operatoren und Pfade angelegt. Dann wird der Parallelisierungsgrad der Operatoren gesetzt. Diese erzeugen "wie zuvor beschrieben, durch das setzen des Parallelisierungsgrades die entsprechende Anzahl an Tasks und Kanälen.

Anschließend erzeugt die Modell-Steuerung eine Zuweisung von Tasks im realen System zu den Tasks im Modell. Die Tasks im Modell sind, wie im vorherigen Kapitel beschrieben, durchnummeriert und haben einen durch das Graph-Modell festgelegten Namen. Diese Namen weichen sehr wahrscheinlich von den Namen im realen CEP-System ab. Damit nun die Messwerte eines realen Tasks konsistent einem modellierten Task zugewiesen werden können, wird pro Operator eine Zuweisungstabelle für die Tasks erzeugt. Diese Zuweisung muss mit jeder Änderung des Parallelisierungsgrades des Operators angepasst werden, da Tasks wegfallen oder hinzu kommen. Ist die Zuweisung erfolgt werden zuletzt die Messwerte über die Kontroll-API in das Modell geladen.

6.3 Steuerung der Skalierung

Die Steuerung der Skalierung übernimmt zwei Aufgaben. Zum Einen werden die Ergebnisse der ausgeführten Algorithmen an das CEP-System geben. Dazu wird die Kontroll-API verwendet, der Adapter steuert die Anpassung der Parallelisierungsgrade in der aktiven Topologie. Als Zweites wird nach erfolgreicher Anpassung der realen Topologie noch das Modell angepasst. Hier werde ebenfalls die neuen Parallelisierungsgrade, welche die Algorithmen berechnet haben, gesetzt.

6.4 Hauptsteuerung

Die Hauptsteuerung ist die zentrale Steuereinheit des Frameworks. Sie enthält die Logik, die die anderen Komponenten kontrolliert und die zuvor beschriebenen Abläufe steuert. Sie instanziiert die anderen Komponenten für jede Topologie, die gesteuert werden soll. Außerdem werden die Parameter definiert, die für Berechnungen in den Algorithmen verwendet werden. Die zeitliche Abfolge aller Abläufe zu steuern ist die Kernaufgabe der Komponente.

6.5 Kontroll-API

Die Kontroll-API abstrahiert die APIs der verschiedenen CEP-Systeme. Grundsätzlich besteht Sie aus zwei Teilen. Ein Teil nimmt die Aufrufe aus dem Framework entgegen und wandelt sie in REST-Anfragen um. Die Anfragen werden anschließend an den entsprechenden Adapter gesendet. So wird die REST-Schnittstelle über die zur Verfügung gestellten Funktionen gekapselt. Dieser Teil ist auf der gleichen Maschine wie die anderen Komponenten des Frameworks und wird direkt von den anderen Komponenten angesprochen.

Die Kommunikation über die REST-API ermöglicht es, dass die beiden teile auf verschiedenen Maschinen installiert sein können. Durch die Fern-Steuerung über die Schnittstelle können mit einer einzelnen Installation des Frameworks mehrere CEP-Systeme und Topologien gleichzeitig gesteuert werden.

6.6 UML-Diagramm des Frameworks

7 Adapter für Heron

Wie bereits in der Architektur des Frameworks beschrieben, stellt der Adpater die Komponente dar, die eine uniforme Steuerung verschiedener CEP-Systeme ermöglicht. Der Adapter kapselt die spezifischen Eigenschaften eines CEP-Systems und dessen API. Die Funktionen des Adapters werden über eine einheitliche REST-Schnittstelle veröffentlicht. So können von einer zentralen Komponente mehrere Adapter über das Netzwerk mit dem HTTP-Protokoll angesprochen werden. Dies ermöglicht die unabhängige Platzierung von CEP-Systemen und des Frameworks. Der Adapter wird normalerweise auf dem Rechner platziert, auf dem die Steuer-Komponente des CEP-Systems liegt. Allerdings muss dies je nach Art der API des CEP-Systems nicht zwingend notwendig sein. Das folgende Kapitel befasst sich mit der Umsetzung des Adapters für das CEP-System Heron.

7.1 Implementierung

Das Ziel des Adapters ist eine ausgewählte Topologie im System ansprechen zu können. Ein Adapter ist daher immer nur für eine spezifische Topologie zuständig. Es ist aber möglich mehrere Adapter auf unterschiedlichen Ports zu starten um mehrere Topologien ansprechen zu können. Diese Entscheidung wurde zur Vereinfachung der REST-API getroffen. So müssen nicht bei jedem Aufruf alle Parameter angegeben werden, die eine spezifische Topologie identifizieren. Die korrekte IP-Adresse und der korrekte Port genügen um den Adapter für eine Topologie anzusprechen. Außerdem können die Merkmale, die eine Topologie identifizieren, bei unterschiedlichen CEP-Systemen variieren. Mit der gewählten Architektur können die Merkmale beim Start des Adapter angegeben werden. Jede Implementation eines Adapters kann die Start-Parameter beliebig festlegen und bietet somit Flexiblität für die Definition der Topologie.

Um den Adapter für Heron zu Starten werden folgende Parameter benötigt:

- URL: Definiert die Adresse unter der der Adapter erreichbar ist.
- Tracker URL: Definiert die Adresse unter der die Heron-API erreichbar ist.
- Cluster: Bestimmt den Cluster in dem die Ziel-Topologie ausgeführt wird.
- Topologie: Der Name mit dem die Topologie identifiziert wird.
- Umgebung: Wird von Heron ebenfalls benutzt um die Topologie zu identifizieren.
- Heron CLI: Spezifiziert den Pfad zu den ausführbaren Programmen von Heron.
- CLI Clustername: Spezifiziert welcher wie das Cluster über die CLI angesprochen werden kann.

 Messwert-Interval: Definiert die Zeitspanne der Messwerte, die ausgelesen werden, in Sekunden.

Der Adapter ist in eine eigenständige JAR-Datei verpackt, die auf jedem Rechner mit installierter Java Laufzeitumgebung ausgeführt werden kann. Beim Ausführen wird ein glassfish-Server gestartet. Dieser nimmt Anfragen über die REST-API entgegen.

Werden über die REST-API Metriken oder der Aufbau der Topologie angefragt, leitet der Adapter die Anfrage an Heron weiter. Heron bietet für die Abfrage von Messwerten selbst eine REST-Schnittstelle an. Die Implementation des Adapters kapselt die REST-Schnittstelle von Heron und abstrahiert sie. Messwerte werden immer für die in den Startparametern definierte Topologie abgefragt. Wie Metriken von Heron bereit gestellt und wie diese vom Adapter angepasst werden ist im folgenden Kapitel detailliert ausgeführt.

7.2 Metriken in Heron

Heron arbeitet mit einem verteilen System für die Erfassung der Messdaten. Alle Container, die einen Task enthalten, sammeln die Messwerte autonom. Jede Minute werden die Werte von den einzelnen Containern zu einer zentralen Einheit, dem sogenannten Metrik-Manager, gesendet. Dieser sammelt die Daten und sichert sie zentral für die Bedienung der Anfragen.

Auf der Webseite von Heron wird angegeben dass die erfassten Messwerte bis zu drei Stunden vorgehalten werden [Noa]. Alle Werte die vor dieser Zeitspanne erfasst wurden sind nicht mehr verfügbar. Die Messwerte von Heron werden in einer Auflösung von einer Minute erfasst und gesichert. Die Messwerte können von Heron als Zeitreihe mit der Auflösung von einer Minute abgefragt werden. Alternativ können die Messwerte von Heron direkt aggregiert abgerufen werden. Da das Graph-Modell nur aggregierte Messwerte und keine Zeitreihen unterstützt, werden vom Adapter direkt die aggregierten Messwerte abgefragt. Der Parameter Messwert-Interval, der definiert werden muss, um den Adapter zu starten, bestimmt die Zeitspanne für die die Messwerte aggregiert werden. Der Endzeitpunkt der Spanne ist immer der Zeitpunkt t, an dem der Adapter die Anfrage an Heron sendet. Wenn der Parameter Messwert-Interval durch s repräsentiert wird so werden alle Werte die in der folgenden Zeitspanne [t-s,t] aggregiert. Heron bietet über die REST-API standardmäßig die untenstehenden auf den Operator bezogenen Messwerte an. Die Metriken unterscheiden sich bei Quell-Operatoren und anderen verarbeitenden Operatoren. Betrachten wir zuerst die Quell-Operatoren:

 __ack-count: Dieser Wert beschreibt die Anzahl an Tupel, die durch das CEP-System bereits erfolgreich abgearbeitet an den Quell-Operator zurückgemeldet wurden. Dieser Messwert wird nur erfasst, falls die Topologie für die Bestätigung der Tupel konfiguriert und implementiert ist.

- __fail-count: Dieser Wert gibt die Anzahl an Tupel an, bei denen während der Verarbeitung
 Fehler aufgetreten sind. Tritt ein Fehler auf wird dies bei entsprechender Implementation
 an den Quell-Operator gemeldet. Dieser Messwert wird nur gemessen, falls die Topologie
 für die Bestätigung der Tupel konfiguriert ist.
- __emit-count: Gibt die Anzahl von Tupel an, die von dem Quell-Operator ausgegeben wurden.
- __complete-latency: Gibt die Gesamtlatenz für eine erfolgreiche Bearbeitung eines Tupels in der Topologie an. Dieser Wert kann von der Quelle berechnet werden, wenn die erfolgreiche Verarbeitung des Tupels zurückgemeldet wird.

Verarbeitende Operatoren:

- __execute-count: Jeder verarbeitende Operator besitzt eine Methode, die von Heron aufgerufen wird und ankommende Tupel verarbeitet. Dieser Wert gibt an, wie oft die verarbeitende Methode aufgerufen wurde. Dieser Messwert gibt keine Aussage über die Anzahl ausgegebener Tupel.
- __ack-count: In der Methode, die die Tupel verarbeitet, kann zu einem beliebigen Zeitpunkt die erfolgreiche Verarbeitung des Tupels an den Quell-Operator signalisiert werden. Dieser Messwert gibt die Anzahl der Tupel an, die von diesem Operator an den Quell-Operator als ërfolgreich Verarbeitetßurückgemeldet wurden.
- __fail-count: Ebenso kann in der Methode, die die Tupel verarbeitet, das Auftreten eines Fehlers an Quell-Operator signalisiert werden. Der Zeitpunkt der Benachrichtigung ist wiederum vollständig von der Implementierung der Methode abhängig. Der Messwert gibt die Anzahl der an den Quell-Operator signalisierten Fehler an.
- __execute-latency: Dieser Messwert beschreibt die durchschnittliche Laufzeit der Methode, welche die Tupel verarbeitet in Nanosekunden. Ein Tupel kann zu jedem beliebigen Zeitpunkt der Methode ausgegeben werden. Tupel können auch an mehreren Zeitpunkten während der Ausführung der Methode ausgegeben werden. Dies bedeutet, dass dieser Messwert nicht zwingend die Dauer bis zur Ausgabe des Tupels darstellt. Dies trifft ebenso für die Benachrichtigungen über Erfolg oder Fehlschlag an den Quell-Operator zu. Ob der Messwert für die Latenz des Tupels im Operator aussagekräftig ist, hängt von der Implementation des Operators ab.
- __process-latency: Dieser Wert gibt die Dauer in Nanosekunden an, die benötigt wurde um die Verarbeitung eines Operators als erfolgreich oder fehlerhaft zu melden. Er misst jedoch nicht die Gesamtlaufzeit des Tupels im System. Gemessen wird ausschließlich die Zeit von Beginn der verarbeitenden Methode bis zu dem Zeitpunkt, an dem die Benachrichtigung, ob das Tupel erfolgreich verarbeitet oder fehlerbehaftet war, erzeugt wird. Die Rückmeldung innerhalb der Methode kann, wie oben beschrieben, zu einem beliebigen Zeitpunkt während der Ausführung geschehen.
- __emit-count: Gibt die Anzahl von Tupel an, die von dem verarbeitenden Operator ausgegeben wurden.

Eine exakte Definition der Messwerte, die von Heron erfasst werden, ist dem momentanen Stand der Heron-Dokumentation nicht zu entnehmen. Dehalb wurde die Bedeutung, der von Heron bereitgestellten Messwerte, empirisch festgestellt.

Alle vorangegangenen Ausführungen beziehen sich auf die Standardeinstellungen von Heron in der Version 17.05. Alle Konfigurationen können in den Files *metrics_sinks.yaml* und textitheron_internals.yaml in dem Verzeichnis des verwendeten Clusters angepasst werden. Außerdem bietet Heron die Möglichkeit Messdaten in Drittsysteme zu exportieren. Somit bietet sich die Möglichkeit für Algorithmen, die auf Basis von alten Daten das Verhalten der Topologie erlernen, Messdaten länger aufzubewahren.

7.3 REST-Schnittstelle

Betrachtet man die im vorherigen Kapitel die standardmäßig von Heron gelieferten Messwerte so ist ersichtlich, dass Heron nicht alle benötigten Messwerte für die REST-Schnittstelle liefert. Deshalb verlangt die Implementation des Adapters, dass die fehlenden Werte bestmöglich approximiert werden. Sämtliche Latenzen werden vor der Weitergabe über die Schnittstelle auf Millisekunden umgerechnet. Im Modell wird von einer Read-Read Latenz ausgegangen, sodass die Bearbeitungsdauer gleich der Latenz des Operators ist. Ein weiterer Punkt ist der Input von Tupeln am Operator. Dieser wird in Heron nicht erfasst. Da im Graph-Modell aber davon ausgegangen wird, dass keine selektive Weiterleitung von Tupeln stattfindet, sind die ausgegebenen Tupel des Vorgänger-Operators gleich den eingehenden Tupel. Die Varianzen der jeweiligen Werte werden mit Hilfe der von Heron gelieferten Zeitreihe berechnet. Die Größe der Stichprobe ist die Anzahl der minütlichen Werte, die von Heron geliefert werden. Sie ist somit von dem gewählten Messwert-Intervall abhängig.

Tabelle 7.1: Operationen der REST-Schnittstelle

Operation	/v1/getalloperators
Ergebnis	["Operator1", "Operator3", "Operator2"]
Beschreibung	Liefert alle Operatoren unsortiert in einem Array mit Strings zurück
Operation	/v1/getlogicaltopology
Ergebnis	{"Pfad1":["Operator1","Operator3"], "Pfad2":["Operator1","Operator2"]}
Beschreibung	Liefert alle Pfade der Topologie als Objekt zurück. Jedes Objekt besitzt ein
	Array mit den Operatoren in korrekter Reihenfolge
Operation	/v1/getoperatorparallelism?operator=Operator3

Tabelle 7.1: Operationen der REST-Schnittstelle

	Tabene 7.1: Operationen der RES1-Schnittstelle		
Ergebnis	4		
Beschreibung	Liefert den Parallelisierungsgrad des Operators als Integer		
Operation	/v1/getpathlatency?operator=Operator1		
Ergebnis	80.3		
Beschreibung	Liefert die durchschnittliche Latenz der Pfade, bei denen der Operator die		
Quelle ist, als Gleitkommazahl in Millisekunden zurück. Die Operation			
	für Quell-Operatoren erlaubt.		
Operation	/v1/getfailedtuplescount?operator=Operator1		
Ergebnis	0.0		
Beschreibung	Liefert die Anzahl der Tupel, bei denen der Operator die Quelle und die Verar-		
	beitung fehlgeschlagen ist. Die Operation ist nur für Quell-Operatoren erlaubt.		
Operation	/v1/getackedtuplescount?operator=Operator1		
Ergebnis	100000.0		
Beschreibung	Liefert die Anzahl der Tupel, bei denen der Operator die Quelle ist und erfolg-		
	reich bearbeiten wurden. Die Operation ist nur für Quell-Operatoren erlaubt.		
0 11			
Operation	/v1/getlatency?operator=Operator2&operation=AVG		
Ergebnis	5.615		
Beschreibung	Liefert die Latenz des Operators als Gleitkommazahl in Millisekunden. Dazu		
	werden die Werte der einzelnen Tasks aggregiert. Erlaubte Operationen sind		
	AVG, SUM, MAX, MIN. Die Operation ist für Quell-Operatoren nicht erlaubt		
Operation	/v1/getoperatorlatency?operator=Operator2		
Ergebnis	{"Task1":5.32, "Task2":5.01}		
Beschreibung	Liefert ein Objekt, das die Tasks des Operators beinhaltet. Jeder Task hat als		
Describening	Wert die Latenz des Tasks als Gleitkommazahl zugewiesen. Die Operation ist		
	für Quell-Operatoren nicht erlaubt.		
	THE QUEL SPECIAL COMMON.		
Operation	/v1/getoperatorlatencyvariance?operator=Operator2		
Ergebnis	{"Task1":3.33, "Task2":3.87}		
Beschreibung	Liefert ein Objekt, das die Tasks des Operators beinhaltet. Jeder Task hat als		
	Wert die Varianz der Latenz des Tasks als Gleitkommazahl zugewiesen. Die		
	Operation ist für Quell-Operatoren nicht erlaubt.		
Operation	/v1/getoutputcount?operator=Operator1&operation=SUM		
Ergebnis	100000.0		

Tabelle 7.1: Operationen der REST-Schnittstelle

Tabelle 7.1: Operationen der REST-Schnittstelle					
Beschreibung	Liefert die Anzahl der Tupel, die der Operator ausgegeben hat. Dazu werden die Werte der einzelnen Tasks aggregiert. Erlaubte Operationen sind AVG, SUM, MAX, MIN.				
Operation	/v1/getoperatoroutputcount?operator=Operator1				
Ergebnis	{"Task1":50000, "Task2":50000}				
Beschreibung	Liefert ein Objekt, das die Tasks des Operators beinhaltet. Jeder Task hat als Wert die Anzahl der Tupel, die der Task ausgegeben hat, zugewiesen.				
Operation	/v1/getoperatoroutputcountvariance?operator=Operator1				
Ergebnis	{"Task1":3.33, "Task2":3.87}				
Beschreibung	Liefert ein Objekt, das die Tasks des Operators beinhaltet. Jeder Task hat als Wert die Varianz der Tupel, die der Task ausgegeben hat, als Gleitkommazahl zugewiesen.				
Operation	/v1/getexecutioncount?operator=Operator2&operation=SUM				
Ergebnis	100000.0				
Beschreibung	Liefert zurück wie oft der Operator ausgeführt wurde. Dazu werden die Werte				
Descriterbung	der einzelnen Tasks aggregiert. Erlaubte Operationen sind AVG, SUM, MAX, MIN. Die Operation ist für Quell-Operatoren nicht erlaubt.				
Operation	/v1/getoperatorexecutioncount?operator=Operator2				
Ergebnis	{"Task1":50000, "Task2":50000}				
Beschreibung	Liefert ein Objekt welches die Tasks des Operators beinhaltet. Jeder Task hat				
	als Wert die Anzahl wie oft der Task ausgeführt wurde. Die Operation ist für				
	Quell-Operatoren nicht erlaubt.				
Operation	/v1/getoperatorexecutioncountvariance?operator=Operator2				
Ergebnis	{"Task1":3.33, "Task2":3.87}				
Beschreibung	Liefert ein Objekt, das die Tasks des Operators beinhaltet. Jeder Task hat als				
	Wert die Varianz der Anzahl wie oft der Task ausgeführt wurde als Gleitkom-				
	mazahl zugewiesen. Die Operation ist für Quell-Operatoren nicht erlaubt.				
0					
Operation	/v1/getinputcount?operator=Operator2&operation=SUM				
Ergebnis	100000.0				
Beschreibung	Liefert die Anzahl der Tupel, die beim Operator angekommen sind. Dazu werden die Werte der einzelnen Tasks aggregiert. Erlaubte Operationen sind AVG, SUM, MAX, MIN. Die Operation ist für Quell-Operatoren nicht erlaubt.				
Operation	/v1/getoperatorinputcount?operator=Operator2				
Ergebnis	{"Task1":50000, "Task2":50000}				

Tabelle 7.1: Operationen der REST-Schnittstelle

	±		
Beschreibung	Liefert ein Objekt, das die Tasks des Operators beinhaltet. Jeder Task hat als		
	Wert die Anzahl der Tupel, die beim Task angekommen sind, zugewiesen. Die		
	Operation ist für Quell-Operatoren nicht erlaubt.		
Operation	/v1/getoperatorinputcountvariance?operator=Operator2		
Ergebnis	{"Task1":3.33, "Task2":3.87}		
Beschreibung	Liefert ein Objekt, das die Tasks des Operators beinhaltet. Jeder Task hat als		
	Wert die Varianz der Tupel, die beim Task angekommen sind, als Gleitkomma-		
	zahl zugewiesen. Die Operation ist für Quell-Operatoren nicht erlaubt.		
Operation	/v1/set operator parallel is m? operator = Operator 2? parallel is m=4		
Ergebnis	true		
Beschreibung	Setzt den Parallelisierungsgrad des Operators auf den definierten Wert. Liefert		
	true wenn der Vorgang erfolgreich war, false wenn nicht.		
Operation	/v1/setmultipleoperatorparallelism?map=Operator2:4;Operator3:2		
Ergebnis	true		
Beschreibung	Setzt den Parallelisierungsgrad der Operatoren auf den definierten Wert. Liefert		
	true wenn der Vorgang erfolgreich war, false wenn nicht.		

7.4 UML-Diagramm

8 Algorithmus mit Warteschlangen-Theorie

Lohrmann et al. beschreiben in ihrem Paper [LJK15] einen Algorithmus, der das Ziel verfolgt, die Latenz der Tupel einer Topologie unter einem, durch den Benutzer bestimmten, Maximalwert zu halten. Dieses Ziel soll mit einem möglichst geringen Verbrauch von Ressourcen erreicht werden. Die Latenz eines Tupels bestimmt sich aus der Zeit, welche das Tupel benötigt um von der Quelle zum Konsument zu gelangen.

Dementsprechend ist die Wahl des Pfades für die Latenz des Tupels essentiell, da die sie mindestens die Summe der Latenz aller Operatoren in einem Pfad ist. Außerdem fließt die Zeit, in der Tupel sich zwischen Operatoren bewegen, in die Latenz des Tupels mit ein. Einerseits beinhaltet dies die Latenz des Netzwerks, über das die Tupel versendet werden. Diese Latenz kann jedoch nicht durch reines Skalieren der Operatoren beeinflusst werden, sondern ist von deren Platzierung abhängig. Im Modell des Algorithmus wird die Netzwerklatenz nicht explizit berücksichtigt. Der zweite Faktor ist die Zeit, welche zwischen der Ankunft eines Tupels im Zwischenspeicher des Operators und der Bearbeitung des Tupels durch den Operator liegt. Diese Zeit zwischen Ankunft und Bearbeitung wird in dem Algorithmus durch ein Modell aus der Warteschlangentheorie abgebildet. Die Dauer, in der sich ein Tupel in der Warteschlange vor der Bearbeitung durch den Operator befindet, wird folgend als Wartezeit bezeichnet. Der Algorithmus bedient sich der Kingman-Formel aus der Warteschlangen-Theorie um die Wartezeit zu berechnen. Sie modelliert eine Warteschlange mit einem einzelnen Abnehmer. Da die genannten Faktoren alle vom gewählten Pfad des Tupels abhängig sind, kann man auch von der Latenz eines Pfades sprechen.

Der Algorithmus von Lohrmann et al. berechnet mit Hilfe der Warteschlangentheorie die Latenz eines Pfades. Diese Berechnung wird für alle Pfade der Topologie ausgeführt. Er vergleicht pro Pfad die berechneten Werte mit dem für den Pfad gegebenen Maximalwert für die Latenz. Der Maximalwert der Latenz des Pfades muss vom Benutzer angegeben werden, bevor der Algorithmus ausgeführt wird. Der Algorithmus versucht den gegebenen Maximalwert für die Latenz des Pfades mit dem geringsten Ressourcenverbrauch zu erreichen. Die Latenz eines Operators wird im Modell des Algorithmus als konstant angenommen. Die Wartezeit verändert sich nach der Formel von Kingman mit der Parallelisierungsgrad des Operators. So stellt die Wartezeit die einzige Möglichkeit dar um die Latenz des Pfades zu anzupassen.

Um minimale Ressourcen zu verbrauchen, startet der Algorithmus bei dem minimalen Parallelisierungsgrad für alle Operatoren. Schrittweise berechnet er dann, bei welchem Operator eine Erhöhung des Parallelisierungsgrades um eins die größte Verringerung der Latenz des Pfades zur Folge hat. Außerdem bestimmt der Algorithmus den Operator, welcher den zweitgrößten Effekt auf die Latenz des Pfades hat. Für den Operator mit dem größten Effekt wird dann durch die von Lohrmann et al. definierte Funktion P_{Δ} ein neuer Parallelisierungsgrad bestimmt. Diese berechnet den neuen Parallelisierungsgrad in Abhängigkeit zum Operator mit dem zweitgrößten Effekt. So soll verhindert werden, dass der Parallelisierungsgrad eines Operators mehrfach hintereinander um eins erhöht wird. Stattdessen wird der Parallelisierungsgrad des gewählten Operators von P_{Δ}

so weit erhöht, dass in der nächsten Runde ein anderer Operator gewählt wird. Diese Schritte werden so lange durchgeführt, bis der Pfad eine Latenz unter dem definierten Maximalwert aufweist.

8.1 Implementation

Im Folgenden sollen die Besonderheiten und Abweichungen vom Original in der vorliegenden Implementation des Algorithmus ausführlich diskutiert werden. Die Implementation des Algorithmus von Lohrmann et al. verwendet das vorgestellte Graph-Modell.

8.1.1 Latenz eines Tupels

Eine weitere Feststellung ist für die Berechnung der Latenz eines einzelnen Tupels notwendig. Laut Lohrmann et al. wird diese von dem Zeitpunkt an dem das Tupel von der Quelle emittiert wird bis zu dem Zeitpunkt an dem das Tupel an dem Konsument aufgenommen wird berechnet. Dabei ist nicht eindeutig definiert, ob die Latenz des Konsument-Operators berücksichtigt wird. In der vorliegenden Implementation wird die Latenz des Konsumentes ebenfalls zur Gesamtlatenz des Tupels gezählt.

8.1.2 Initialisierung

Für die fehlerfreie Berechnung des Parallelisierungsgrades ist es notwendig, dass das Modell so initialisiert ist, dass die zwischengespeicherten Messwerte größer als 0 sind. Ist dies nicht der Fall kann es zu Divisionen durch 0 führen. Daher wird vor der eigentlichen Ausführung des Algorithmus das Modell auf die korrekte Initialisierung geprüft. Falls dies nicht zutrifft, wird eine IllegalStateException geworfen, welche angibt, dass das Modell nicht ordnungsgemäß initialisiert ist.

8.1.3 Minimaler Parallelisierungsgrad und Flaschenhals

Die Wartezeit von Operator i wird von Lohrmann et. al mit der folgenden Funktion berechnet: [LJK15]:

$$W(p_i^*) = e\left(\frac{\lambda_i S_i^2 p_i}{p_i^* - \lambda_i S_i p_i}\right) \left(\frac{c_{Ai}^2 + c_{Si}^2}{2}\right)$$

Der Wert des Koeffizienten e resultiert aus einer Angleichung der Ergebnisse des Modells an die Messwerte des realen CEP-Systems. Er wird im nächsten Kapitel gesondert diskutiert. λ ist die durchschnittliche Tupel-Ankunftsrate pro Millisekunde welche mit

$$\frac{1}{Tupel-Ankunftsintervall}$$

berechnet wird. S beschreibt die Bearbeitungsdauer in Millisekunden. p ist der aktuelle Parallelisierungsgrad des Operators. Die aktuellen Messwerte aus dem CEP-System sind für diesen Parallelisierungsgrad gültig. p^* ist der potentielle neue Parallelisierungsgrad des Operators. Der

Algorithmus versucht die Wartezeit durch das optimieren von p^* so anzupassen, dass die Latenzbeschränkung des Pfades eingehalten wird. Dabei aber möglichst wenig Ressourcen verwendet werden. Der letzte Teil der Formel berechnet einen Koeffizienten aus den Varianzen der Bearbeitungsdauer und der Tupel-Ankunftsrate. Essentiell für die folgenden Ausführungen ist vor allem der Nenner $p_i^* - \lambda_i S_i p_i$.

Ein wichtiges Detail ist, dass ein negativer Nenner für die Funktion nicht sinnvoll ist. Da die anderen beiden Koeffizienten immer positiv sind würde ein negativer Nenner im Ergebnis zu einer negativen Wartezeit führen. Eine negative Wartezeit ist aber real nicht möglich, deswegen ist die Formel für diesen Anwendungsfall ungültig, wenn sie einen negativen Nenner besitzt. Des Weiteren ist die Funktion offensichtlich ungültig wenn nach der Subtraktion im Nenner eine Null steht.

Um diese Probleme zu verhindern legen Lohrmann et al. fest, dass die Berechnungen des Algorithmus nur gültig sind, wenn in der Topologie keine Flaschenhälse vorhanden sind. Ein Flaschenhals wird als ein Operator mit einer Auslastung von 100% oder nahe 100% definiert. Um einen Flaschenhals aufzulösen wird im vorgeschlagenen Algorithmus der Parallelisierungsgrad des Operators verdoppelt. Falls die Auslastung höher als eins ist, wird der Parallelisierungsgrad noch mit der momentanen Auslastung multipliziert. Da der Parallelisierungsgrad eine Ganzzahl sein muss, muss das Produkt zu einem Integer umgewandelt werden. In der vorliegenden Implementation werden die Kommastellen nach der Multiplikation abgeschnitten und nicht gerundet. Bei einer Verdoppelung des Parallelisierungsgrades übt die maximale Differenz von 1 keinen starken Einfluss aus und der Code ist leichter zu lesen. Lohrmann et al. treffen selbst keine Aussage zu dieser Problematik.

Jedoch ist die Methode, Flaschenhälse in der Topologie aufzulösen, nicht ausreichend um die zuvor beschriebenen Probleme zu verhindern. Die Auflösung der Flaschenhälse sorgt nur dafür, dass die Bedingung $0 < \lambda S < 1$ erfüllt ist. Um einen Nenner > 0 zu erhalten muss aber die Bedingung $p^* > \lambda Sp$ erfüllt sein. Nehmen wir den Grenzwert 1 für die Auslastung (λS an. Dies bedeutet immer wenn $p \geq p^*$ zutrifft ist der Nenner null oder negativ. Lässt man die Auslastung gegen den Grenzwert 0 gehen, so ist der Nenner unter der Bedingung $p \gg p^*$ null oder negativ. Wie im ersten Teil dieses Kapitels beschrieben, berechnet der Algorithmus zu Beginn die Wartezeit mit dem minimalen Parallelisierungsgrad. Wie in Kapitel ******* beschrieben ist es gewöhnlich, dass dieser eins beträgt. Wir nehmen an der Algorithmus startet mit dem potentiellen Parallelisierungsgrad $p^*=1$. Der momentan im System aktive Parallelisierungsgrad p bleibt für einen gesamten Durchlauf des Algorithmus konstant. Da $p^* = 1$ ist es nicht unwahrscheinlich, dass $p \gg p^*$ zutrifft und somit der Nenner ≤ 0 ist. Dies ist für die Anwendung aber nicht zulässig und stellt deshalb ein Fehler im von Lohrmann et al. vorgestellten Algorithmus dar. Die Berechnung des Algorithmus darf nicht in allen Fällen mit dem im Modell festegelegten minimalen Parallelisierungsgrad von eins beginnen. Stattdessen ist die Auswahl des minimalen Parallelisierungsgrades eines Operators wie folgt zu definieren: $max(p_min, \lambda Sp+1)$. Die Erhöhung um eins ist notwendig um zu Verhindern, dass der Nenner null wird. Diese Änderung wurde in der vorliegenden Implementation des Algorithmus umgesetzt.

8.1.4 Ausnahme bei Flaschenhals mit maximalem Parallelisierungsgrad

Wie zuvor beschrieben wird beim Auftreten einen Flaschenhalses der Parallelisierungsgrad des Operators verdoppelt. Dabei kann es vorkommen, dass der maximale Parallelisierungsgrad eines Operators überschritten wird. Die Implementation des Algorithmus wirft in diesen Fall eine Ausnahme, welche besagt dass der Operator trotz maximalem Parallelisierungsgrad ein Flaschenhals ist. Es wird keine weitere Anpassung unternommen.

8.1.5 Ausnahme bei nicht ausreichendem Parallelisierungsgrad

Nachdem die Flaschenhälse aufgelöst wurden, prüft der Algorithmus, ob es mit der momentanen Konfiguration möglich ist den Grenzwert für die Latenz des Pfades zu erreichen, Dazu wird die Latenz für den Fall berechnet, dass alle Operatoren bis zum maximalen Parallelisierungsgrad skaliert sind. Ist dies nicht der Fall, werden in der originalen Version des Algorithmus ohne weitere Mitteilung alle Operatoren maximal skaliert. In der vorliegenden Implementation wurde dieses Verhalten geändert, sodass eine IllegalStateException geworfen wird. Diese sagt aus, dass der maximale Parallelisierungsgrad nicht ausreichend ist. Eine Anpassung des Parallelisierungsgrades findet demnach nicht statt.

8.1.6 Verhindere Loop durch zu kleinen Parallelisierungsgrad

Wenn der Algorithmus schrittweise die Parallelisierungsgrade der Operatoren optimiert, wird die Funktion $P_-\delta$ aufgerufen. Sie bestimmt den nächsten Parallelisierungsgrad des Operators. Entgegen der Intention der Funktion, dass in der nächsten Runde des Algorithmus ein anderer Operator gewählt wird, liefert Sie teilweise den aktuellen Parallelisierungsgrad des Operators. Der Parallelisierungsgrad des gewählten Operators ändert sich dementsprechend nicht. Dies führt offensichtlich dazu, dass er in der nächsten Runde wieder gewählt wird, da alle Parameter der Warteschlangen-Funktion identisch geblieben sind. Dieses Verhalten führt zu einer endlosen Schleife im Algorithmus. Um das Problem zu beheben wird in der Implementation das Ergebnis der Funktion P_Δ geprüft. Sei p der momentane Parallelisierungsgrad des Operators. Das Ergebnis der Funktion P_Δ ist p_Delta . Dann bestimmt sich der zukünftige Parallelisierungsgrad des Operators aus dem Maximum $max(p+1,p_Delta)$.

8.1.7 Parallelisierungsgrad des letzten Operators

In einem Spezialfall des Algorithmus wird die von Lohrmann et al. definierte Funktion P_w verwendet. Sie bestimmt den Parallelisierungsgrad des letzten verbleibenden Operators, wenn alle anderen Operatoren bereits maximal skaliert sind. Allerdings weist diese im von Lohrmann et al. definierten Algorithmus keine Beschränkung durch den maximalen Parallelisierungsgrad des Operators auf. Es treten somit Fälle auf, in denen die Funktion einen Parallelisierungsgrade über dem Maximum zurückliefert. Theoretisch sollte der Maximalwert nicht überschritten werden, denn zu Beginn überprüft der Algorithmus ob der Grenzwert für die Latenz unter maximaler Skalierung erreicht werden kann. Dass dieser Fall dennoch eintritt hängt mit der im nächsten Kapitel beschriebenen Problematik zusammen. Um diesen Fehler zu vermeiden wird in dieser

Implementation das Ergebnis der Funktion geprüft und auf den maximalen Parallelisierungsgrad gesetzt, falls es diesen übersteigt.

8.1.8 Koeffizient e

Im Folgenden wird der Einfluss des Koeffizienten e auf die Funktion P_w untersucht. Die Funktion ist wie folgt definiert:

$$P_w(i, w) = \left\lceil \frac{a_i}{w} + \lambda_i S_i p_i \right\rceil$$

$$a_i = \lambda_i S_i^2 p_i \left(\frac{c_{Ai}^2 + c_{Si}^2}{2} \right)$$

Der Parameter i bestimmt dabei den Index des Operators. Der Parameter w ist definiert als die für den Operator maximal erlaubte Wartezeit, um den Grenzwert für die Gesamtlatenz für den Pfad nicht zu überschreiten. Diese ist bekannt, da i der letzte Operator ist, der noch nicht maximal skaliert ist. Außerdem folgt aus der initialen Prüfung, dass die maximale Latenz zumindest bei maximaler Parallelisierung erreicht werden kann.

Die Funktion P_w ist die nach p_i^* umgestellte Variante der Funktion $W(p_i^*)$, die die Wartezeit eines Operators abhängig vom Parallelisierungsgrad bestimmt. Die umgestellte Formel bestimmt nun den Parallelisierungsgrad eines Operators abhängig von der maximal erlaubten Warteschlangenzeit w. Allerdings wurde bei der Umstellung der Formel der Koeffizient e nicht berücksichtigt oder aus Pw absichtlich entfernt.

Koeffizient e beschreibt die prozentuale Abweichung der gemessenen Wartezeit zur berechneten Wartezeit aus der Kingman-Formel. Er wird in der Funktion W benutzt um die Abweichung von Modell und realem System auszugleichen. e wird wie folgt berechnet:

$$e_i = \frac{l_{ji} - obl_{ji}}{Kinqman_i}$$

wobei l_{ji} die Latenz des Kanals zwischen Operator i und dessen Vorgänger j beschreibt. Die Latenz der Stapelverarbeitung am Ausgang von j wird durch obl_{ji} repräsentiert. Ist die Netzwerklatenz in l_{ji} nicht Berücksichtigt ist die Differenz der beiden Latenzen ist die effektive Wartezeit eines Tupels im realen System.

Durch die fehlende Berücksichtigung von e kann der aus P_w resultierende Parallelisierungsgrad stark von dem in W angenommenen Wert abweichen. Angenommen die maximale Warteschlangendauer w=1 wird in der Funktion W durch den Parallelisierungsgrad $p^*=1$ erfüllt. Es gilt also W(1)=1. Gleichzeitig nehmen wir an, dass e=0,5 beträgt. Der gemessene Wartezeit beträgt also nur 50% des berechneten Wartezeit W(1)=2*0,5. Der Koeffizient passt den berechneten Wert entsprechend an. Berechnet man nun Pw für w=1 wird ein Parallelisierungsgrad von 2 zurückgeliefert, da dieser nicht um den Faktor e=0,5 angeglichen wurde. Der aus Pw resultierende Parallelisierungsgrad verschwendet also Ressourcen wenn angenommen wird, dass W(p) korrekt ist und der Parallelisierungsrad p=1 genügt um w=1 zu erfüllen.

Nehmen wir nun an, dass p=1 der maximale Parallelisierungsgrad eines Operators ist. Um zu prüfen ob der Operator die maximal erlaubte Warteschlangenzeit w=1 erfüllen kann, wird mit

W(1)=1 geprüft ob er mit maximaler Auslastung diesen Wert erreicht
. Pw bestimmt nun die tatsächliche Ausprägung des Parallelisierungsgrades und liefert den Wert 2, der den maximalen Parallelisierungsgrad überschreitet.

Drastischer ist das Problem für den Fall, dass der Faktor e>1 ist. Dann würde der gemessene Wert größer als der berechnete Wert sein. Nehmen wir an e=1.5, W(3)=1 und W(3)=(2/3)*1.5 sowie w=1. Das Ergebnis von W ergibt, dass sich die maximale Warteschlangenzeit durch den Parallelisierungsgrad von 3 erfüllen lässt. Wird nun der Parallelisierungsgrad durch Pw berechnet resultiert daraus 2. Somit würde durch den geringeren Parallelisierungsgrad der Maximalwert für die Latenz des Pfades verletzt.

Um diesem Problem entgegen zu wirken, wird in der Implementation des Algorithmus das Ergebnis von P_w mit dem Koeffizienten e multipliziert.

8.2 Parameter

Dieser Bereich beschreibt die Parameter, mit welchen der Algorithmus gesteuert werden kann. Parameter die in der originalen Version des Algorithmus von Lohrmann et al. fix definiert waren, wurden für die Implementation parametrisiert um flexibler zu sein. Der Algorithmus berücksichtigt die neben den speziell dem Algorithmus zugewiesenen Parametern noch den maximalen und minimalen Parallelisierungsgrad aus dem Graph-Modell. Die folgenden Parameter sind als finale statische Attribute in der Klasse für den Algorithmus zu finden.

8.2.1 Flaschenhals Grenzwert

Name: BOTTLENECK_THRESHOLD

Standardwert: 1.0

Wie von Lohrmann et al. beschrieben ist der Algorithmus ungültig wenn die Topologie einen Flaschenhals aufweist. Ein Operator wird als Flaschenhals definiert, wenn er eine Auslastung von 100% oder nahezu 100% hat. Für die Implementation wurde der Grenzwert von 100% nicht als Konstante sondern als konfigurierbarer Parameter umgesetzt. Der Wert kann als Dezimalzahl angegeben werden, sodass 1.0 = 100% Auslastung entspricht. Ein Wert von größer als 1.0 zu setzen ist für den Algorithmus nicht zulässig. Allerdings könnte es für eine schnellere Skalierung der Operatoren interessant sein, dass der Grenzwert für einen Flaschenhals auf einen niedrigeren Wert gesetzt wird.

Allerdings ist zu beachten, dass der Wert nicht zu niedrig angesetzt sein darf, da sonst immer abwechselnd gegensätzliche Aktionen durch den Algorithmus angestoßen werden. Im ersten Durchlauf erkennt er einen Flaschenhals, zum Beispiel mit einem Grenzwert von 50%. Daraufhin wir der Parallelisierungsgrad des Operators verdoppelt. Beim nächsten Lauf ist der Flaschenhals nicht mehr vorhanden und der Algorithmus verwendet die Funktion der Wartezeit. Er versucht die maximale Latenz des Pfades mit möglichst wenig Ressourcen zu unterschreiten. Deshalb ist es sehr wahrscheinlich, dass er den zuvor verdoppelten Parallelisierungsgrad wieder zurück setzt um Ressourcen zu sparen. Im darauf Folgenden lauf wird dies dazu führen, dass der Operator wieder als Flaschenhals erkannt wird.

8.2.2 Koeffizient für Stapelverarbeitung

Name: ADAPTIVE_BATCHING_COEFFICIENT

Standardwert: 0.8

Wertebereich $0 \le x < 1$

Die Idee der Stapelverarbeitung ist, dass Tupel am Ende eines Operators gesammelt werden und gleichzeitig über das Netzwerk gesendet werden können. Durch die Zusammenfassung der Tupel kann der Overhead für Netzwerkprotokolle verringert und somit der Durchsatz an Tupel verringert werden. Allerdings steigt durch die Wartezeit im Stapel die Latenz. Lohrmann et al. beschreiben in [LWK14] adaptive Stapelverarbeitung. Sie beschreiben ein System welches die Stapelgröße am Ende eines Operator dynamisch ändert, anstatt wie bei anderen CEP-Systemen, die Größe systemweit zu fixieren. Der Name des Parameters ist darauf zurück zu führen, dass der vorgestellte Algorithmus auf dem CEP-System Nephele aufbaut, für das die adaptive Stapelverarbeitung implementiert wurde. Jedoch ist die Aufgabe des Parameters im Algorithmus generell für jede Stapelverarbeitung zutreffend.

Der Parameter ist ein Koeffizient welcher die Dauer beschreibt, die ein Tupel in dem Ausgangsstapel eines Operators liegt. Er wird als Anteil der maximalen Latenz des Pfades angegeben. Die effektive maximale Latenz eines Pfades berechnet der Algorithmus durch das Produkt aus diesem Parameter und der maximalen Latenz des Pfades.

8.2.3 Schrittweite

Name: DELTA_STEP_SIZE

Standardwert: 1

Wertebereich $1 \le x$

Dieser Parameter legt die Schrittweite fest, mit der der Algorithmus den Operator bestimmt, der den größten Einfluss auf die Latenz des Pfades hat. In jeder Runde berechnet der Algorithmus die Wartezeit aller Operatoren. Die Berechnung wird mit dem Parallelisierungsgrad , der um die definierte Schrittweite erhöht ist, durchgeführt. Anschließend vergleicht er, welcher Operator die Gesamtlatenz mit dem neuen Parallelisierungsgrad am stärksten verringern würde. Die Schrittweite dient aber ausschließlich zur Auswahl des Operators. Der Parallelisierungsgrad des Operators wird anschließend von der Funktion P_{Δ} festgelegt. Deswegen ist der Standardwert von eins durchaus sinnvoll. Ein höherer Wert wäre interessanter, wenn die Operatoren um die Schrittweite ebenfalls direkt erhöht werden würden. Für die vorliegende Version des Algorithmus führt die Abweichung vom Standardwert sehr wahrscheinlich zu einem höheren Verbrauch an Ressourcen.

8.2.4 Verwendung der Latenz der Kanäle

Name: USE_LATENCY_ADAPTION

Standardwert: true

Wertebereich Boolean

Im einem vorhergehenden Kapitel wurde die Berechnung des Koeffizienten e untersucht. Mit dem Koeffizienten wird versucht die berechnete Wartezeit an die Tatsächliche Wartezeit im System anzupassen. Dazu wird die mit dem aktuellen Parallelisierungsgrad errechnete Wartezeit eines Operators mit der tatsächlich gemessenen Wartezeit ins Verhältnis gesetzt. Das Messen der Wartezeit im realen System ist je nach Support des CEP-Systems nicht trivial. Lohrmann et al. definieren die gemessene Wartezeit als LatenzdesKanals - LatenzderStapelverarbeitung. Die Messung der Latenz des Kanals ist jedoch ein nicht triviales Problem, sobald Operatoren sich über mehrere Rechner verteilen. Die Uhren der Hosts exakt synchron zu halten ist nicht realisieren. Somit ist die Messung der Latenz des Kanals nie korrekt.

Ein weiteres Detail ist das Verhältnis der Netzwerklatenz zu der Wartezeit. Wie zu Beginn dieses Kapitels beschrieben, ist die Wartezeit die variable Größe, die durch den Algorithmus optimiert wird. Die Netzwerklatenz wird, wie die Latenz des Operators, als konstant angenommen. Sind Operatoren über mehrere Rechner verteilt ist die Netzwerklatenz in der Latenz des Kanals enthalten. Aus empirischer Erfahrung in der Testumgebung ist die Netzwerklatenz ein essentieller Teil der Latenz des Kanals. Nehmen wir an dass die Netzwerklatenz einen Anteil von 90% an der Gesamtlatenz von 10 ms hat. Somit wäre die gemessene Wartezeit bei 1 ms. Das Ergebnis für die Berechnung der Wartezeit durch die Kingman Formel liefert ebenfalls 1 ms. Sie trifft also die reale Wartezeit des Tupels exakt. Wenn die Latenz der Stapelverarbeitung mit null beziffern wird der Koeffizient e wird nun wie folgt berechnet:

$$e = \frac{LatenzdesKanals}{Kingman} = \frac{10/1}{=}10$$

Dies würde bedeuten dass der Algorithmus die berechnete Wartezeit des Operators verzehnfacht. Anschließend würde er versuchen die verzehnfachte Wartezeit über den Parallelisierungsgrad des Operators zu verringern. Real ist der Anteil der Netzwerk-Latenz aber konstant. Im realen System werden durch die Skalierung somit nur 10% der berechneten Verringerung der Wartezeit effektiv erreicht. Der Algorithmus neigt deshalb dazu sehr hohe Parallelisierungsgrade zurück zu geben, die in der realen Topologie aber nur einen geringen Effekt auf die Latenz des Pfades bewirken.

Daher ist eine Adaption der berechneten Wartezeit durch den Koeffizienten e nur sinnvoll, wenn die effektive Wartezeit im realen System bestimmt werden kann. In der Implementation wurde daher der hier beschriebene Parameter eingeführt, um die Adaption durch den Koeffizienten e abzuschalten zu können. Dieser wird sinnvoller Weise auf *false* gesetzt wenn die Wartezeit im CEP-System nicht bestimmt werden kann.

9 Algorithmus mit Regression

Als weitere Option zum Skalieren der Topologie wurde der Algorithmus von Zacheilas et al. [Zac+15] für das Framework implementiert. Er berechnet, im Gegensatz zum von Lohrmann et al., nicht die gegenwärtige Auslastung des Systems sondern bedient sich der Regression um den zukünftigen Zustand des Systems vorherzusagen. Dies bedeutet konkret, dass der Algorithmus versucht präventiv auf zukünftige Ereignisse zu reagieren, während der der Algorithmus mit Warteschlangen-Theorie reaktiv agiert. Das Ziel des Algorithmus ist die Topologie möglichst vorausschauend anzupassen.

Um den zukünftigen Zustand des Systems vorherzusagen verwenden Zacheilas et al. Gauss-Prozesse. Gauss-Prozesse sind nicht-lineare Regressions-Verfahren und können für mehrdimensionale Regressionen verwendet werden [rasmussen2004gaussian]. Im Speziellen werden mit Hilfe des Gauss-Prozesses die verpassten Tupel eines Operators vorhergesagt. Verpasste Tupel sind alle Tupel die über ein Zeitfenster am Operator angefallen aber in diesem nicht abgearbeitet worden sind. Mit Hilfe eines Gauss-Prozesses können die verpassten Tupel mit Abhängigkeit zur Zeit und zum Parallelisierungsgrad des Operators vorhergesagt werden.

Um die optimalen Zustandsübergänge zu finden werden nun alle Kanten mit Gewichten versehen. Die Gewichte der Kanten werden mit einer von Zacheilas et al. definierten Kostenfunktion bestimmt. Sie ist eine gewichtete Summe mit drei Summanden und wird durch folgenden Term definiert[Zac+15]:

$$C(v_{ij}v_{i'j'}) = VT_{i'j'} \times C_A + p' \times C_B + S(i,i') \times C_C$$
$$S(i,i') = \begin{cases} 0 & \text{wenn } i = i' \\ 1 & \text{sonst} \end{cases}$$

Der Erste der Summanden ist die Anzahl der verpassten Tupel im zukünftigen Zustand $VT_{i'j'}$, die mit einem benutzerdefinierten Kostenfaktor C_A multipliziert werden. Der zweite Summand erfasst die Kosten der Ressourcen, die benötigt werden um einen Operator auszuführen. Die Kosten

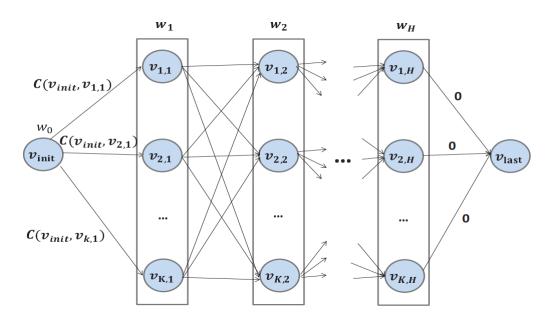


Abbildung 9.1: Graph der Zustandsübergänge [Zac+15].

errechnen aus dem Produkt des zukünftigen Parallelisierungsgrades p' und den benutzerdefinierten Kosten C_B eines einzelnen Tasks. Der dritte Teil der Summe berücksichtigt den Aufwand, der durch skalieren eines Operators entsteht. Das CEP-System muss hierzu die Verarbeitung der Tupel kurzfristig stoppen und das Routing in der Topologie anpassen. Die Kostengewichtung C_C ist ebenfalls durch den Benutzer zu bestimmen. Sind alle Kanten gewichtet kann anschließend mittels eines Algorithmus, der den kürzesten Pfad ermittelt, die optimale Abfolge von Zustandsübergängen berechnet werden. Der erste Zustand in der gefundenen Abfolge bestimmt den Parallelisierungsgrad des Operators.

9.1 Implementation

Im Folgenden sollen die Besonderheiten der Implementierung des Algorithmus für das Framework diskutiert werden. Für die Implementation des Graphen der Zustandsübergänge wurde die Bibliothek JGraphT [noauthor_welcome_nodate] verwendet. Diese liefert ebenfalls eine Implementation des Dijkstra-Algorithmus um den kürzesten Pfad im Graphen zu bestimmen. Die Umsetzung der Regression mittels Gauss-Prozessen erfolgte mit der Bibliothek Smile [noauthor_smile_nodate].

9.1.1 Training des Vorhersagemodells

Die Implementation verwendet ebenfalls das Graph-Modell des Frameworks. Allerdings wird für die Vorhersage eine Historie der Messdaten aus dem CEP-System benötigt. Da das Graph-Modell des Frameworks aber nur den aktuellen Status der Topologie repräsentiert, ist dieses nicht ausreichend. Um das Modell für die Regression zu trainieren, werden deshalb CSV-Dateien eingelesen. Das Regressions-Modell wird zu Beginn für alle Operatoren trainiert, sodass während

des aktiven Betriebs nur noch das Graph-Modell verwendet wird. Während dem Betrieb können die Regressions-Modelle der einzelnen Operatoren jeweils einzeln aktualisiert werden. Ddie Laufzeit eines Training-Vorgangs beträgt $O(n^3)$ [Zac+15]. Aufgrund der Laufzeit ist es sinnvoll Operatoren während der Laufzeit einzeln aktualisieren zu können. Bei der Aktualisierung des Modells eines Operators wird das alte Modell verworfen und durch ein neues ersetzt. Das neue Modell wird ausschließlich aus den zuletzt eingelesenen Daten erzeugt.

Außerdem werden in der momentan implementierten Version des Algorithmus andere Eingabewerte als in der Originalversion verwendet. Ursprünglich werden der momentane Zeitstempel, die Tageszeit und der Wochentag für die Vorhersage der eingehenden Tupel verwendet. Um die ausgehenden Tupel vorherzusagen wird zusätzlich der Parallelisierungsgrad des Operators verwendet. Da die Evaluation für Zeiträume in der Größenordnung weniger Stunden vorgesehen ist, ist die Verwendung dieser Werte nicht sinnvoll. Die Tageszeit und der Wochentag wurden daher entfernt und durch die Zeit ersetzt, die seit Beginn der Evaluation vergangen ist.

9.1.2 Vorhersage von verpassten Tupeln

Ein essentieller Teil des Algorithmus ist die Kostenfunktion die auf der korrekten Vorhersage von verpassten Tupeln beruht. Zacheilas et al. berechnen die Tupel wie folgt [Zac+15]:

 $Verpasste Tupel = Anzahl eingehender Tupel \times Selektionsrate - Anzahl ausgegebener Tupel$

Die Selektionsrate stellt dabei das Verhältnis der Anzahl ausgegebener Tupel pro eingehendem Tupel dar. Die Selektionsrate eines Operators wird als konstant angenommen. Die Vorhersage von Verpassten Tupeln basiert daher auf der Vorhersage der Anzahl eingehender Tupel und der Anzahl ausgehender Tupel. Ausgehende Tupel werden im von den Autoren vorgestellten System aber nicht gemessen. Sie berechnen die Anzahl der ausgehenden Tupel basierend auf der vergangenen Zeit, dem Parallelisierungsgrad, der vorhergesagten Latenz des Operators und der Anzahl eingehender Tupel. Da das in dieser Arbeit vorgestellte Framework die Daten für ausgehende Tupel liefert wird die Anzahl ausgehender Tupel für die Umsetzung des Algorithmus nicht berechnet. Stattdessen werden anstatt der Latenz des Operators direkt die Anzahl ausgehender Tupel vorhergesagt.

9.1.3 Kern der Gauss-Prozesse

Für die Regression der Anzahl eingehender und ausgehender Tupel werden vom Algorithmus sogenannte Gauss-Prozesse verwendet. Sie ermöglichen zu einem n-dimensionalen Eingabevektor $x \in \mathbb{R}^n$ eine Schätzung des Zielwertes y zu berechnen. Für diese Schätzung bedienen sich Gaußprozesse einer sogenannten Kovarianz-Matrix. Die Kovarianz-Matrix wird mit einer Kovarianz-Funktion aus einem gegebenen Datensatz, den Trainingsdaten, berechnet. Die Trainingsdaten bestehen aus mehreren n-dimensionalen Eingabevektoren x und deren zugehöriger Zielwert y. Die Kovarianz-Funktion k(x,x') bestimmt die Korrelation zwischen zwei Eingabevektoren $x \in \mathbb{R}^n$ aus den Trainingsdaten. Die Wahl der Kovarianz-Funktion hat dabei maßgeblichen Einfluss auf die berechnete Korrelation der Werte und somit auch auf das Modell des Gauss-Prozesses. Eine Kovarianz-Funktion muss per Definition symmetrisch sein [rasmussen2004gaussian]. Die

Symmetrie der Kovarianz-Funktion bedeutet, dass k(x,x')=k(x,x') gilt. Im Bereich des maschinellen Lernens wird die Kovarianz-Funktion auch Kern genannt. Somit besitzt jeder Gauss-Prozess einen symmetrischen Kern, mit dessen Hilfe die Kovarianz-Matrix für die Vorhersage berechnet wird

Zacheilas et al. verwenden für Ihre Vorhersagemodelle folgenden Kern:

$$k(x, x') = \sigma^2 \exp\left(-\frac{1}{2} \sum_{d=1}^n \frac{x_d - x'_d}{\lambda_d}\right)$$

$$k(x, x') = \sigma^2 \exp\left(-\frac{1}{2} \sum_{d=1}^n \frac{|x_d - x'_d|}{\lambda_d}\right)$$

Grundsätzlich ist der Kern in Smile als Java-Interface implementiert und somit durch jede beliebige Kovarianz-Funktion austauschbar.

9.1.4 Pfad-Zurückweisung

Zacheilas et al. sehen in der Originalversion des Algorithmus eine Zurückweisung eines gefundenen kürzesten Pfades vor. Die durch die Verwendung des Gauss-Prozesses vorhergesagten Werte unterliegen einer Normalverteilung. Mit Hilfe der Standardabweichung der Normalverteilung kann berechnet werden, wie wahrscheinliches es ist, dass der vorhergesagte Mittelwert eintrifft [Zac+15]. Diesen Umstand nutzen die Autoren um einen gefundenen Pfad zurückzuweisen, falls der Eintritt des vorhergesagten Wertes zu unwahrscheinlich ist. Diese Funktionalität ist in der momentanen Version der vorliegenden Implementation im Framework nicht vorhanden.

9.2 Parameter

Dieser Abschnitt beschreibt die Parameter die es ermöglichen den Algorithmus anzupassen. In dem Fall des Regression-Algorithmus dienen Sie hauptsächlich dazu das unterliegende Kosten- und Regressionsmodell anzupassen. Wie bei dem Algorithmus mit Warteschlangentheorie werden die im Graph-Modell festgelegten minimalen und maximalen Parallelisierungsgrade berücksichtigt. Die folgenden Parameter sind als finale statische Attribute in den Klassen der Implementation des Algorithmus zu finden.

9.2.1 Trainingsdaten

Name: INPUT_TRAINING_DATA_FOLDER / OUTPUT_TRAINING_DATA_FOLDER

Standardwert: null

Wertebereich: alphanumerisch

Gibt den Pfad zu dem Ordner mit den Dateien an, die die Trainingsdaten für die Regressionsmodelle beinhalten. Die Daten müssen im CSV-Format bereitgestellt werden. Dabei ist zu beachten, dass als Trennzeichen das Leerzeichen erwartet wird. Für jedes Vorhersagemodell wird eine eigene Datei mit Daten benötigt. Es wird somit erwartet, dass in dem angegebenen Verzeichnis zwei Dateien pro Operator vorliegen. Eine Datei beinhaltet die Daten für die Vorhersage der Anzahl eingehender Tupel. Die Andere stellt die Daten für die Vorhersage der Anzahl ausgehender Tupel bereit. Die Datei für eingehende Tupel muss folgenden Namen besitzen: "<Operator>_input_train.csv". Analog gilt für ausgehende Tupel "<Operator>_output_train.csv".

Die Trainingsdaten für eingehende Tupel bestehen momentan aus drei Spalten. Als Daten für den Eingabevektor: Unix-Zeitstempel in Sekunden, Sekunden seit Start der Anwendung. In der letzten Spalte wird die Zielvariable Anzahl eingegangener Tupel erwartet. Die Trainingsdaten für ausgehende Tupel umfassen vier Spalten. Eingabevektor: Unix-Zeitstempel, Sekunden seit Start der Anwendung, Parallelisierungsgrad. Wieder in der letzten Spalte muss die Anzahl ausgehender Tupel stehen. Die Anzahl der Spalten für eingehende und ausgehende Tupel wird über einen Enumerator gesteuert. Dieser muss angepasst werden, falls sich die Spaltenanzahl ändert. Ebenso muss die Dimension von λ mit der Dimension der Eingabewerte übereinstimmen.

9.2.2 Hyperparameter

Tabelle 9.1: Hyperparamter

Name	Standardwert	Wertebereich		
SIGMA_INPUT	1.0	$x \in \mathbb{R} > 0$		
LAMBDA_INPUT	(1.0, 1.0)	$x \in \mathbb{R}^2 > 0$		
SIGMA_OUTPUT	1.0	$x \in \mathbb{R}0$		
LAMBDA OUTPUT	(1.0, 1.0, 1.0)	$x \in \mathbb{R}^3 0$		

Die Hyperparameter dienen hauptsächlich der Konfiguration des Kernels. Sigma ist eine Größe mit der der Kernel multipliziert wird. Der Parameter kann dazu verwendet werden die Korrelation der Werte grundsätzlich zu verkleinern oder zu vergrößern. Lamda wird verwendet um die Komponenten des Eingabevektors zu gewichten. Für den verwendeten Kernel bedeutet das, dass der negative Exponent kleiner wird wenn lambda größer wird. Im Umkehrschluss fällt die Korrelation für diesen Wert des Eingabevektors höher aus.

Der Wert für den Zeitstempel verdient besondere Beachtung. Da der Zeitstempel einen absoluten Zeitpunkt markiert, verändert sich die Korrelation mit jeder Anwendung des Kernels. Hier muss das lambda gegebenenfalls nachjustiert werden. Das lambda für die Vorhersage der ausgehenden Tupel sollte zusätzlich berücksichtigen, dass der Parallelisierungsgrad im Normalfall eine kleinere Größenordnung als die anderen Werte besitzt. Daher weist der Parallelisierungsgrad tendenziell

höhere Korrelationen auf als die anderen Komponenten. Dieser Umstand sollte gegebenenfalls mit lambda ausgeglichen werden.

9.2.3 Kostenfunktion

Die vorgestellte Kostenfunktion bietet drei verschiedene Eingabegrößen, die durch den Benutzer getätigt werden müssen. Die Kostenfunktion implementiert ein Interface und wird bei der Erzeugung der Regressionsmodelle als Parameter übergeben Somit ist die Kostenfunktion gegen andere Varianten austauschbar. Die Kostenfaktoren der Funktion können über den Konstruktor angegeben werden. Bei einem parameterlosen Aufruf des Konstruktors initialisiert dieser die Funktion mit eins.

10 Evaluation

Im diesem letzten Teil der Arbeit sollen die beiden Implementationen der Algorithmen evaluiert und miteinander verglichen werden. Für die Evaluation sollen die Algorithmen das CEP-System Heron über das implementierte Framework kontrollieren, während ein möglichst realitätsnaher Strom von Tupeln vom System abgearbeitet werden muss.

10.1 Testdaten

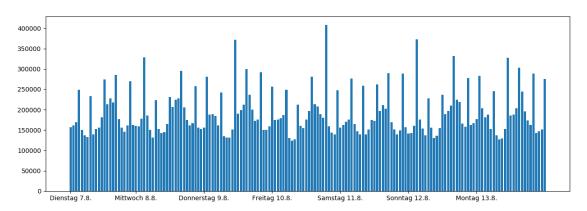


Abbildung 10.1: Anzahl Tupel pro Stunde.

10.2 Systemaufbau

Die Evaluation wurde auf dem internen OpenStack-Cluster des Instituts für Verteile und Parallele Systeme der Universität Stuttgart durchgeführt. Für die Evaluation wurde ein Cluster aus vier virtuellen Maschinen aufgebaut. Die Maschinen werden mit dem Betriebssystem Ubuntu 14.04 betrieben. Drei der virtuellen Maschinen sind je mit 24 CPU-Kernen, 32 GB Arbeitsspeicher und 50 GB persistentem Speicher ausgestattet. Diese Maschinen führen während der Evaluation die aktiven Tasks aus. Die vierte Maschine wird als Steuer-Knoten genutzt und arbeitet mit 4 CPU-Kernen, 8 GB RAM sowie 10 GB persistentem Speicher. Auf der vierten Maschine wird ausschließlich der Ablauf der Evaluation gesteuert. Somit sind die Maschinen, die Tasks der Topologie ausführen, identisch. Der Cluster wird über den Apache Aurora-Scheduler in der Version 0.13 gesteuert. Der Scheduler von Aurora so wie die Steuerung des CEP befinden sich auf diesem Knoten. Auf jedem der drei anderen Rechner ist die ausführende Instanz von Aurora ebenfalls in der Version 0.13 installiert. Um die Arbeitspakete an die ausführenden Knoten auszuliefern, wird das verteile Dateisystem HDFS von Apache Hadoop in der Version 3.0.3 verwendet. Der Adapter für das implementierte Framework wird ebenfalls auf diesem Rechner gestartet. Zusätzlich benötigen die Systeme Apache Zookeeper um den verteilten Zustand zu speichern. Dieser ist ebenfalls als Cluster über alle vier virtuellen Maschinen konfiguriert.

10.3 Heron

Für die Evaluation wurde das CEP-System Heron gewählt [kulkarni_twitter_2015]. Heron ist ein Nachfolger von Apache Storm. Die Twitter Inc. entwickelte Heron als Nachfolger für den produktiv verwendeten Storm Cluster. Sie entwickelten Heron als schnelleres und besser skalierendes System, da Storm den Anforderungen nicht mehr gerecht werden konnte [kulkarni_twitter_2015]. Heron wird von Twitter momentan als produktives System für die Analyse von Datenströmen eingesetzt. Heron wurde für diese Evaluation aus zwei Gründen gewählt. Einerseits ist aufgrund der produktiven Verwendung und aktiven Entwicklung bei Twitter ist davon auszugehen, dass das System aktuellen realen Anforderungen gerecht wird. Zweitens wurde ein System gesucht, mit dem die Algorithmen möglichst unabhängig bewertet werden können. Viele der in Kapitel ********* vorgestellten Algorithmen wurden auf Basis eines bestimmten CEP-Systems entwickelt. Einige dieser CEP-Systeme sind Eigenentwicklungen oder erweiterte Frameworks auf bestehenden CEP-Systemen, die von den Autoren entwickelt werden. Apache Storm wird ebenso, als eines der bekanntesten CEP-Systeme, oft als Basis für die Entwicklung von neuen Algorithmen verwendet. Mit Heron können verschiedene Algorithmen getestet werden, ohne dass manche den Vorteil besitzen nativ für das CEP-Systems entwickelt worden zu sein.

Eine wichtige Neuerung bei Heron ist besonders hervorzuheben: Das System bietet die Möglichkeit eine Topologie über eine autonome Strom-Regulation zu steuern. Bei vielen anderen Systemen werden Tupel einfach verworfen, wenn die Kapazität eines Operators nicht mehr ausreicht. Dieses Verhalten wird als sogenannter Lastabwurf bezeichnet. Dies führt dazu, dass Tupel entweder verloren gehen oder von der Quelle erneut ausgegeben werden. Wird ein Tupel neu ausgegeben, muss es alle Operatoren erneut durchqueren. Diese Verhalten zusätzliche Last auf dem System verursachen und den Engpass noch verstärken. Die neue Regulation in Heron wird aktiviert, wenn ein Operator die ankommende Menge von Tupel nicht mehr verarbeiten kann. Dies wird

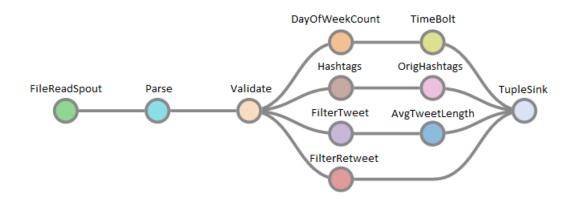


Abbildung 10.2: Darstellung der logischen Topologie durch Heron UI.

von der Topologie erkannt und die Quellen werden daraufhin gestoppt. Somit gelangen keine neuen Tupel mehr in die Topologie. Der Stopp wird so lange aufrecht erhalten, bis der Operator wieder genügend Kapazität für neue Tupel geschaffen hat.

Diese Methode, den Datenstrom zu drosseln, verändert die Erkennung von Operatoren die Flaschenhälse bilden gänzlich. Messwerte, auf die viele der in Kapitel 4 vorgestellten Algorithmen reagieren, verhalten sich anders. Dies trifft auch für die beiden implementierten Algorithmen zu. Diese gehen im Grundprinzip davon aus, dass bei einem Flaschenhals die Anzahl ankommender Tupel größer als die Anzahl abgearbeiteter Tupel ist. Dieser Zustand kann aber nicht mehr auftreten, wenn die Quelle den Zufluss von neuen Tupeln automatisch stoppt. Somit würde ein Operator gar nicht oder nur sehr schwach von den Algorithmen skaliert werden. Deswegen wurde dieses Verhalten für die Evaluation der beiden Implementationen deaktiviert.

Die Evaluation wurde mit Heron unter der aktuellen Version 0.17.5 durchgeführt. Die System-Parameter wurden im Standard belassen und nicht verändert.

10.4 Topologie

Für die Durchführung der Evaluation wurde eine eigene Topologie entwickelt. Diese liest die von der Twitter API gesammelten Tupel aus und analysiert sie auf deren Eigenschaften. Der logische Aufbau der Topologie ist in der Abbildung 10.2 dargestellt. Ziel bei der Erstellung der Topologie war, dass es Operatoren mit unterschiedlich großen Lasten gibt. Entweder wurde der Datenstrom durch eine Filteroperation für den Folgeoperator verkleinert oder die Operation des Operators rechenintensiv gestaltet.

Topologien in Heron besitzen Parameter, durch die der Entwickler das Verhalten beeinflussen kann. Für nahezu alle Parameter definiert Heron einen Standardwert. Im Folgenden werden die Parameter beschrieben, bei der die Evaluations-Topologie vom Standard abweicht. Die Parameter sind in Tabelle 10.1 mit den zugewiesenen Werten aufgelistet.

Wie schon im vorherigen Kapitel beschrieben wurde die Regulation des Tupel-Stroms deaktiviert. Die Topologie wurde so konfiguriert, dass jedes Tupel mindestens einmal erfolgreich verarbeitet

Tabelle 10.1: Parameter der Topologie

Parameter	Wert
TopologyDropTuplesUponBackpressure	True
TopologyReliabilityMode	ATLEAST_ONCE
MessageTimeoutSecs	60
MaxSpoutPending	1000000

werden muss. Deshalb werden Tupel, die in der Folge eines Flaschenhalses verworfen werden, mehrfach von der Quelle ausgegeben. Dies ist möglich, weil die Bestätigung von Tupel aktiviert wurde. Dies bedeutet, dass jeder Operator die Bearbeitung des Tupels an die Quelle zurückmeldet. Erst wenn alle Operatoren die Verarbeitung des Tupel bestätigen, wird das Tupel als bestätigt markiert. Durch diesen Mechanismus ist es ebenfalls möglich die Latenz des Tupels zu bestimmen. Die Quelle wurde so konfiguriert, dass ein Tupel, das innerhalb von einer Minute nicht erfolgreich verarbeitet wurde, ungültig ist und wiederholt werden muss. Außerdem sendet die Quelle maximal 1.000.000 Tupel, ohne dass eines davon bestätigt wurde. Das bedeutet, dass sich zu jedem Zeitpunkt maximal 1.000.000 Tupel zur Bearbeitung in der Topologie befinden. Dieser Wert wurde bewusst sehr groß gewählt, um die Ausgabe von Tupeln nicht aufgrund von Flaschenhälsen in der Topologie zu verringern. So ist sichergestellt, dass die Quelle dauerhaft in der Lage ist Tupel auszugeben, um den realistischen Arbeitsaufwand zu rekonstruieren.

In der momentanen Version kann Heron die Operatoren nur skalieren, wenn die Tupel zufällig den Tasks der Operatoren zugewiesen werden. Deswegen wurde diese Konfiguration für die Operatoren der Topologie gewählt. Außerdem erhält jeder Folgeoperator immer alle ausgegebenen Tupel des Vorgängers. Es gibt also keine selektive Weiterleitung. Jedem Task wurde eine CPU, 1,25 GB RAM und 1,25 GB persistentem Speicher zugewiesen. Die Topologie wurde mit der Java API von Heron entwickelt. Diese erlaubt das definieren eigener Logik für die Quelle und die anderen Operatoren. Im Folgenden werden die einzelnen Operatoren der Topologie beschrieben.

10.4.1 Quelle

Die Quelle "FileReadSpout" liest die gesammelten Daten von der Festplatte. Dies geschieht Zeile für Zeile was jeweils einem Tupel entspricht. Jedes erfasste Tupel besitzt einen Zeitstempel mit dem Zeitpunkt, an dem es erzeugt wurde. Um den Twitter-Datenstrom realistisch nachzubilden wird dabei immer der Zeitstempel des eingelesenen Tupels überprüft. Um die Topologie auszulasten ist der Datenstrom in der realen Geschwindigkeit, mit der er erfasst wurde, nicht ausreichend. Deshalb wird die Zeit in der die Tupel verarbeitet wurden, auf eine kleineren Zeitraum komprimiert. So bleibt die Struktur des Arbeitsaufwandes wie Lastspitzen und Lastabfall erhalten, wird aber in ein kürzeres Intervall geschoben um so insgesamt mehr Last zu erzeugen. Das Ziel ist, dass in jeder realen Minute in der Evaluation 84 Minuten der aufgezeichneten Daten verarbeitet werden. Somit werden in einer realen Stunde 84 Stunden der aufgezeichneten Daten. Da eine Woche 168 Stunden hat dauert ein Durchlauf der Evaluation 2 Stunden. Die Quelle wurde so implementiert, dass sie den Startzeitpunkt der Topologie sowie den Zeitstempel des ersten Tupels in Millisekunden speichert. Während der Evaluation wird geprüft wie viele Millisekunden seit dem Start der Topologie vergangen sind. Mit diesen Werten kann der maximale Zeitstempel errechnet werden, mit dem ein Tupel die Quelle verlassen darf. Der maximale Zeitstempel errechnet sich

aus der Differenz von aktuellem Zeitstempel und der Startzeit der Topologie die mit dem Faktor 84 multipliziert und zu dem Zeitstempel des ersten Tupels addiert wird. Mit dieser Methode kann nicht garantiert werden, dass Tupel nicht langsamer ausgegeben werden, aber es wird verhindert, dass die Tupel schneller als der realistische Arbeitsaufwand ausgeben werden. Die Leserate vom permanenten Speicher ist in der verwendeten Implementation wesentlich höher als die Rate des realistischen Arbeitsaufwandes, sodass eine langsamere Abgabe der Tupel unrealistisch ist.

10.4.2 Andere Operatoren

Um die folgenden Beschreibungen zu verstehen, sind folgende Erläuterungen notwendig. Ein Retweet ist ein Statusupdate welches das Statusupdate eines anderen Nutzers ohne weitere Anmerkung weiterverbreitet. Ein Antwort-Tweet ist ein Statusupdate, welches auf das Statusupdate eines anderen Nutzers antwortet. Ein Tweet zitiert einen anderen Tweet wenn er ihn weiterverbreitet und Anmerkungen hinzufügt.

- "Parse": Dieser Operator liest das Tupel, das einen String, der ein JSON-Objekt beschreibt, und liest alle Daten des JSON Objektes aus. Anschließend werden ausgewählte Daten weiter gesendet. Löschanfragen für Statusmeldungen werden nicht weitergeleitet.
- "Validate": Dieser Operator prüft die Lesbarkeit der Daten und gibt sie auf der Standardausgabe aus.
- "DayOfWeekCount": Hier wird der Zeitstempel des Tupels in den Wochentag, an dem das Tupel erzeugt wurde, umgerechnet. Jedes Tupel erhöht den Zähler für den jeweiligen Tag.
- "TimeBolt": Dieser Operator gibt den genauen Datumstext für den Zeitstempel des Tupels auf der Standardausgabe aus.
- "Hashtags": Hier werden die Hashtags des Tweets ausgelesen. In einer Tabelle werden identische Hashtags gezählt.
- "OrigHashtags": Zählt ebenso Hashtags, allerdings nur für Original-Tweets eines Retweet oder Antwort-Tweet.
- "FilterTweet": Sendet nur Tweets weiter, die kein Retweet und kein Antwort-Tweet sind sowie keinen anderen Tweet zitieren.
- "AvgTweetLength": Berechnet die durchschnittliche Länge des verfassten Textes.
- "FilterRetweet": Sendet ausschließlich Retweets weiter.
- "TupleSink": Hat keine Operation außer die Tupel final zu bestätigen.

10.5 Ablauf

In der Evaluation mussten die zuvor implementierten Algorithmen die Topologie steuern, während Sie die Tupel im Zeitfenster von zwei Stunden verarbeitet. Für jeden der beiden Algorithmen von Lohrmann et al. und Zacheilas et al. wurden fünf Durchläufe gestartet. Jeder Durchlauf startet mit dem aktivieren des Clusters. Die Hauptsteuerung wurde so implementiert, dass sie alle fünf Minuten die Topologie durch den gewählten Algorithmus prüfen lässt. Zuerst werden alle Messwerte des Graph-Modells mit den aktuellen Messwerten aus der Topologie aktualisiert. Anschließend wurden die folgenden Daten zur Evaluation erfasst:

- Minuten seit Beginn der Evaluation
- Sekunden seit Beginn der Evaluation
- Durchschnittliche Latenz der Tupel
- Anzahl fehlgeschlagener Tupel
- · Anzahl bestätigter Tupel
- Summe der Parallelisierungsgrade der Operatoren

Die Anzahl der Minuten und Sekunden seit Beginn der Evaluation ist dabei um fünf Minuten verschoben, da der Erste Start der Hauptsteuerung erst zur ersten Prüfung erfolgt, nachdem die Topologie schon 5 Minuten aktiv ist. Wenn alle Messwerte erfasst sind, startet der gewählte Algorithmus und die Topologie wird entsprechend der Empfehlung des Algorithmus skaliert. Erst nachdem der Vorgang erfolgreich von Heron zurückmeldet wurde, beginnt das Zeitfenster von 5 Minuten bis zur nächsten Prüfung.

Während Heron die Topologie skaliert ist diese gestoppt, sodass während dieser Zeit keine neuen Tupel von der Quelle ausgegeben werden. Dies wirkt sich offensichtlich auf die Zeitbeschränkung für die Tupel-Ausgabe der Quelle aus, da die Zeit, die seit Beginn der Evaluation vergangen ist, trotzdem weiter läuft. Dies spiegelt auch das reale Verhalten wieder, da der reale Datenstrom ebenfalls zwischengespeichert werden müsste, solange die Topologie skaliert. Während des Vorgangs löscht Heron außerdem alle Messdaten, da die alten Daten für den aktuellen Zustand der Topologie nicht mehr gültig sind. Nachdem die Topologie wieder gestartet wurde, müssen sich die Zwischenspeicher vor und nach den Operatoren erst wieder mit Tupel füllen, um aussagekräftige Messwerte zu erhalten. Deswegen ist es sinnvoll erst nach Abschluss des Vorgangs weitere fünf Minuten zu warten, bis die Messwerte im System wieder aussagekräftig sind. Außerdem werden aus diesem Grund bei der Abfrage der Messwerte, die ebenfalls im Interval von fünf Minuten ausgelesen werden, nur die letzten drei Minuten aus dem CEP-System angefordert. Dies bedeutet, dass die Messwerte der ersten zwei Minuten, nachdem die Topologie skaliert wurde, weder für die Berechnung des Parallelisierungsgrades noch für die Ergebnisse der Evaluation verwendet wurden. Die Evaluation stoppt sobald alle Tupel verarbeitet wurden.

10.6 Parametrisierung der Algorithmen

Für die Durchführung der Evaluation mussten die beschriebenen Parameter der Algorithmen definiert werden. Das GraphModell war so konfiguriert, dass der minimale Parallelisierungsgrad

Tabelle 10.2: Parameter für den Warteschlangenalgorithmus

Parameter	Wert
BOTTLENECK_THRESHOLD	1.0
ADAPTIVE_BATCHING_COEFFICIENT	0.0
DELTA_STEP_SIZE	1
USE_LATENCY_ADAPTION	False

eins und der maximale zehn beträgt. Da jeder Task eines Operators eine CPU, und 1,25 RAM verbraucht, konnte der maximale Parallelisierungsgrad nicht höher als 10 gesetzt werden.

Für die Evaluation wurden für den Warteschlangen-Algorithmus die in der Tabelle 10.3 gelisteten Parameter gewählt. Wie im Original von Lohrmann et al. wurde die Erkennung eines Flaschenhalses ab einer Auslastung von 100% gesetzt. Der Koeffizient für adaptives Batching wurde auf null gesetzt, da Heron diese Methode nicht verwendet. Der Parameter bestimmt ohnehin nur den Anteil der maximalen Latenz des Pfades, der für adaptives Batching reserviert ist. So kann dieser Anteil auch direkt bei der Angabe der maximalen Latenz berücksichtigt werden, wenn der Parameter auf null steht. Die Schrittweite des Algorithmus wurde ebenfalls wie im Original auf eins gesetzt. Die Verwendung des Koeffizienten e wurde deaktiviert, da die gemessene Latenz im Vergleich zu der vom Algorithmus berechneten Latenz sehr hoch war. Dies hätte wie in Kapitel 8.2.4 beschrieben dazu geführt, dass der Algorithmus sehr hohe Parallelisierungsgrade vorgeschlagen hätte. Dies hätte in Kombination mit dem maximalen Parallelisierungsgrad von zehn zur Folge gehabt, dass die Topologie während der Evaluation konstant maximal skaliert ist und nie angepasst wird.

Für den Algorithmus, der Regression zur Vorhersage verwendet wurden die in Tabelle 10.4 gezeigte Parametrisierung gewählt. Die Trainingdaten für den Algorithmus wurden während der Evaluation des Lohrmann Algorithmus gesammelt. Alle fünf Minuten, in denen die neuen Metriken aus dem System abgerufen wurden, wurden für jeden Operator die Anzahl eingegangener und ausgegangener Tupel der letzten drei Minuten mit Zeitstempel versehen und gespeichert. Da die aus der Topologie bezogenen Messdaten vom aktuellen Zustand der Topologie und nicht von den verwendeten Twitter-Daten abhängen, sind auch Fehler reflektiert, die vom Algorithmus von Lohrmann et al. gemacht werden. Somit ist garantiert, dass die verwendeten Trainingsdaten das Vorhersage-Modell nicht speziell für den vorliegenden Twitter-Datensatz übertrainiert wird.

Die Hyperparameter wurden für die Evaluation nicht mathematisch optimiert. Sie wurden lediglich so gewählt, dass die Regression Vorhersagen im richtigen Größenbereich trifft. Dazu wurden die Zeitstempel sehr schwach gewichtet. Die Zeit, die seit der Evaluation vergangen ist, wurde stark gewichtet, da sie einen größeren Zusammenhang mit dem Zustand der Topolgie aufweiste als der Zeitstempel. Da das Modell für eingehende Tupel nur auf den beiden Dimensionen Zeitstempel und vergangene Zeit beruht, muss die vergangene Zeit stark gewichtet werden um zu verhindern, dass der Zeitstempel das Modell verfälscht. Für die Vorhersage der ausgehenden Tupel wurde die Gewichtung des Parallelisierungsgrad so gewählt, dass er sich in etwa gleich wie die vergangene Zeit auf die Korrelation auswirkt. Wie in Kapitel 9.2.2 erwähnt besitzen der Parallelisierungsgrad und die Zeit, die seit der Evaluation vergangen ist, verschiedene Größenordnungen. In der Evaluation bewegen sich Parallelisierungsgrade im Einerbereich währen die

Tabelle 10.3: Parameter für den Algorithmus mit Regression

Parameter	Wert
SIGMA_INPUT	1.0
LAMBDA_INPUT	(1.0, 10000.0)
SIGMA_OUTPUT	1.0
LAMBDA_OUTPUT	$(1.0, 10000.0 \ 10.0)$
Kostenfunktion	(1.0, 1.0, 1.0)
Abstand Zeitfenster (300 sec)	
Anzahl Zeitfenster (6)	

Zeit bis zu 7200 steigt. Diese Tatsache wird durch den gewählten Wert des Hyperparameters ausgeglichen.

Die Kostenfunktion wurde für alle Kostenfaktoren mit eins initialisiert. Dies fördert die Flexibilität der Topologie, da die Kosten, die Topologie zu ändern, und die Kosten pro verwendeten Task sehr gering sind. Die Anzahl verpasster Tupel kann jedoch schnell 1000 übersteigen, sodass die Kosten für verpasste Tupel ausschlaggebend für den kürzesten Pfad im Graphen der Zustandsübergänge sind. Die Vorhersagen wurden für Zeitfenster von fünf Minuten getroffen, um dem gleich dem Intervall zu sein, in dem die Topologie geprüft wird. Es wurden jede Runde Vorhersagen für sechs Zeitfenster getroffen, sodass immer Zustandsübergänge für die nächsten 30 Minuten berücksichtigt wurden.

10.7 Ergebnisse

Letzte wird nie parallelisiert bei zacheilas Lohrmann hat vorteil, weil 2 Minuten nicht gemessen werden Zacheilas bewegt sich im bekannten gefilde Selten max erreiht, Ressourcen kein problem

11 Zusammenfassung und Ausblick

Hier bitte einen kurzen Durchgang durch die Arbeit.

Ausblick

...und anschließend einen Ausblick

Literaturverzeichnis

- [LJK15] B. Lohrmann, P. Janacik, O. Kao. "Elastic Stream Processing with Latency Guarantees". en. In: IEEE, Juni 2015, S. 399–410. ISBN: 978-1-4673-7214-5. DOI: 10.1109/ICDCS. 2015.48. URL: http://ieeexplore.ieee.org/document/7164926/ (besucht am 18. 04. 2018) (zitiert auf S. 35, 36).
- [LWK14] B. Lohrmann, D. Warneke, O. Kao. "Nephele streaming: stream processing under QoS constraints at scale". en. In: *Cluster Computing* 17.1 (März 2014), S. 61–78. ISSN: 1386-7857, 1573-7543. DOI: 10.1007/s10586-013-0281-8. URL: http://link.springer.com/10.1007/s10586-013-0281-8 (besucht am 23.04.2018) (zitiert auf S. 41).
- [Noa] *Heron Metrics*. URL: https://apache.github.io/incubator-heron/docs/operators/heron-tracker-api/#topologies metrics (zitiert auf S. 28).
- [Wee+05] S. Weerawarana, F. Curbera, F. Leymann, T. Storey, D. F. Ferguson. Web Services Platform Architecture: SOAP, WSDL, WS-Policy, WS-Addressing, WS-BPEL, WS-Reliable Messaging, and More. Prentice Hall PTR, 2005. ISBN: 0131488740. DOI: 10.1.1/jpb001 (zitiert auf S. 11).
- [Zac+15] N. Zacheilas, V. Kalogeraki, N. Zygouras, N. Panagiotou, D. Gunopulos. "Elastic complex event processing exploiting prediction". In: IEEE, Okt. 2015, S. 213–222. ISBN: 978-1-4799-9926-2. DOI: 10.1109/BigData.2015.7363758. URL: http://ieeexplore.ieee.org/document/7363758/ (besucht am 06. 06. 2018) (zitiert auf S. 43–46).

Alle URLs wurden zuletzt am 14. 10. 2018 geprüft.

Erklärung

Ich versichere, diese Arbeit selbstständig verfasst zu haben. Ich habe keine anderen als die angegebenen Quellen benutzt und alle wörtlich oder sinngemäß aus anderen Werken übernommene Aussagen als solche gekennzeichnet. Weder diese Arbeit noch wesentliche Teile daraus waren bisher Gegenstand eines anderen Prüfungsverfahrens. Ich habe diese Arbeit bisher weder teilweise noch vollständig veröffentlicht. Das elektronische Exemplar stimmt mit allen eingereichten Exemplaren überein.

Ort, Datum, Unterschrift